Deep Learning

Bagian A

1. **Efek Regularisasi pada Batch Normalization (Slide 6–8)**

   Slide 8 menyebutkan bahwa Batch Normalization "acts like mild regularization" dan "often eliminates the need for Dropout".

   - Jelaskan mekanisme statistik mini-batch yang menimbulkan efek regularisasi tersebut.
     Jawab: Batch Normalization menghitung **mean** dan **variance** dari setiap mini-batch (batch dengan size sangat kecil) dengan rumus:

     $$\mu_B = \frac{1}{m}\sum_{i=1}^{m} x_i$$

     $$\sigma_B^2 = \frac{1}{m}\sum_{i=1}^{m} (x_i - \mu_B)^2$$

     (setiap mini-batch berisi data yang berbeda, nilai mean dan variance juga berubah-ubah/berbeda pula)

     Perbedaan di nilai mean dan variance tersebut menimbulkan noise kecil pada representasi data, sehingga model tidak terlalu mudah menghafal data training. Ini yang membuat BN memiliki efek (mirip dengan) mild regularization karena bisa digunakan untuk mengatasi/mengurangi efek overfitting yang dimana model terlalu hafal dengan data training nya.

   - Uraikan kondisi atau skenario spesifik ketika asumsi "menghilangkan Dropout" ini tidak lagi berlaku atau justru dapat memicu instabilitas pelatihan.

     Jawab: Batch Normalization tidak (terlalu) menggantikan Dropout, rather hanya meniru fungsi Dropout. Pada batch size yang sangat kecil (mini-batch), estimasi mean dan variance menjadi kurang stabil sehingga dapat menyebabkan training tidak stabil pula / inconsistent. Hal yang sama dapat terjadi jika distribusi data antar batch sangat berbeda, karena dapat menyebabkan statistik BN untuk berubah terlalu besar. Dan jika model masih mengalami overfitting, Dropout tetap dapat diperlukan sebagai regularisasi tambahan.

     Kesimpulannya, BN dapat mengurangi the need to use Dropout, instead of completely replacing it.

2. **Degradasi Jaringan Dalam dan Formulasi Residual (Slide 10–12)**

   - Mengapa penambahan kedalaman lapisan pada plain CNN (tanpa sambungan residual) justru menurunkan akurasi pelatihan (degradation problem), padahal secara teoritis representasi model yang lebih dalam minimal dapat menyamai model dangkal via fungsi identitas (identity mapping)?

Jawab: Pada plain CNN, dengan adanya layer/lapisan yang semakin banyak/dalam, gradient harus melewati semakin banyak operasi saat backpropagation.

Jika kebanyakan turunan turn out bernilai kecil, hasil perkaliannya semakin kecil pula, sehingga terjadi vanishing gradient. Akibatnya, layer awal sulit belajar dan akurasi training justru dapat menurun (degradation problem).

Model yang lebih dalam seharusnya bisa menyamai model dangkal dengan identity mapping, tetapi optimizer sulit menemukan mapping tersebut karena proses training terhambat oleh gradient yang mengecil.

- Jelaskan bagaimana skip connection mengubah formulasi aliran gradien saat propagasi balik (backpropagation).

  Jawab:

  Rumus saat backpropagation:

  $$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial y}\left(1 + \frac{\partial F(x)}{\partial x}\right)$$

  Tambahan 1 dalam rumus berasal dari skip connection. Artinya, gradient memiliki jalur langsung dari output ke input tanpa harus melewati semua layer di $F(x)$.

- Hubungkan mekanisme tersebut dengan mitigasi fenomena vanishing gradient yang telah dibahas pada Sesi 02.

  Jawab: Skip connection → gradient lebih mudah mengalir → vanishing gradient berkurang → deep network lebih mudah dilatih.

3. **Feature Extraction vs. Fine-Tuning (Slide 14–16)**

   Bandingkan pendekatan Feature Extraction (membekukan backbone) dengan Fine-Tuning (membuka sebagian atau seluruh lapisan) ditinjau dari empat dimensi:

   - Jumlah parameter yang diperbarui (trainable parameters).

     Jawab:
     Feature Extraction: hanya classifier/head yang diperbarui
     Fine Tuning: sebagian atau seluruh backbone ikut diperbarui

   - Kebutuhan volume data latih.

     Jawab:
     Feature Extraction: lebih sedikit karena fitur bawaan tidak diubah
     Fine Tuning: membutuhkan lebih banyak data agar update fitur tidak overfit

   - Beban komputasi dan memori per epoch.

     Jawab:
     Feature Extraction: lebih ringan dan cepat karena backbone dibekukan

Fine Tuning: lebih berat karena gradient harus dihitung dan disimpan untuk layer yang dilatih

- Risiko rusaknya fitur representasi bawaan (destructive gradient updates). Sintesiskan kriteria praktis kapan masing-masing pendekatan paling tepat dipilih.

  Jawab:
  Feature Extraction: sangat rendah karena backbone tidak berubah
  Fine Tuning: lebih tinggi karena gradient dapat mengubah fitur pretrained yang sudah berguna

4. **Kaidah Penerapan Data Augmentation (Slide 20, 21, 23)**

   - Jelaskan pertimbangan metodologis mengapa pipeline data augmentation hanya diaktifkan pada train set dan harus dinonaktifkan pada validation/test set.

     Jawab: Data augmentation digunakan untuk menambah variasi data training agar model lebih robust dan mengurangi overfitting. Augmentation hanya diterapkan pada train set karena validation/test set harus merepresentasikan data asli yang belum dimodifikasi.

     Jika augmentation juga diterapkan pada validation/test, distribusi data evaluasi dapat berubah dan hasil evaluasi menjadi kurang mencerminkan performa model pada data nyata. Selain itu, jika transformasinya menggunakan informasi dari keseluruhan dataset, dapat terjadi data leakage.

   - Berikan satu contoh teknik transformasi citra yang tidak layak digunakan untuk klasifikasi ras hewan peliharaan (pet breeds), dan jelaskan argumentasi ketidaklayakannya berdasarkan invariansi semantik label.

     Jawab: Rotasi 180° pada gambar hewan peliharaan.

     Untuk klasifikasi ras, rotasi gambar sebesar 180° dapat menghasilkan gambar dengan orientasi yang sangat tidak natural dan mengubah karakteristik visual yang biasanya digunakan model untuk mengenali ras.

5. **Mitigasi Catastrophic Forgetting (Slide 28–29)**

   Slide 28 mengingatkan potensi terjadinya catastrophic forgetting apabila proses adaptasi model berlangsung terlalu agresif.

   - Uraikan bagaimana fenomena hilangnya representasi bawaan tersebut terjadi.

     Jawab: Catastrophic forgetting terjadi ketika model pretrained di fine tuned dengan learning rate terlalu besar atau update yang terlalu agresif. Gradient dari dataset baru mengubah bobot backbone secara signifikan, sehingga representasi dan fitur yang sebelumnya sudah dipelajari dari pretraining dapat terhapus atau terganggu.

Akibatnya, model memang semakin cocok dengan task baru, tetapi dapat kehilangan kemampuan atau representasi bawaan yang sebelumnya berguna.

- Jelaskan dua strategi mitigasi konkret (misalnya differential learning rate, gradual unfreezing, atau linear warmup) beserta alasan teoritis mengapa strategi tersebut efektif.

  Jawab:
  A. Differential Learning Rate

  Gunakan learning rate yang berbeda untuk bagian model yang berbeda.

  Alasannya, backbone sudah memiliki fitur yang berguna sehingga tidak perlu diubah secara drastis. Learning rate kecil membuat perubahan bobot lebih gradual dan mengurangi risiko merusak representasi pretrained.

  B. Gradual Unfreezing

  Awalnya hanya classification head yang dilatih, sementara backbone dibekukan. Setelah head mulai stabil, beberapa layer backbone dibuka secara bertahap.

  Dengan cara ini, model tidak langsung mengubah seluruh representasi pretrained sekaligus. Adaptasi menjadi lebih terkendali sehingga risiko catastrophic forgetting berkurang.

Bagian B - Experiment Praktik

Dataset: Oxford-IIIT Pet

Colab link:
https://colab.research.google.com/drive/1L1_0Sl6hxRrgByuXHjO4bl1BL50PpHxq?usp=sharing

Bagian C - Laporan dan Analisis

Doc link:

https://docs.google.com/document/d/1MC4C8ITrx_rIX28f6KpqmXskLPBp5Tcud0HKH_f9s0U/edit?usp=sharing