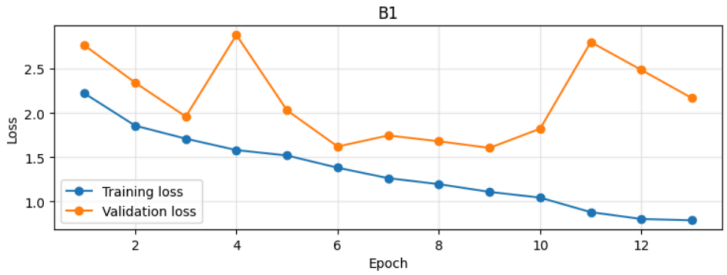
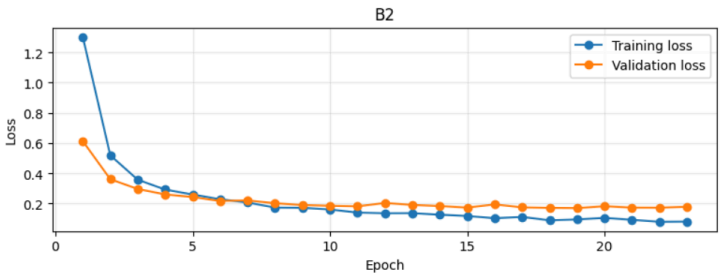
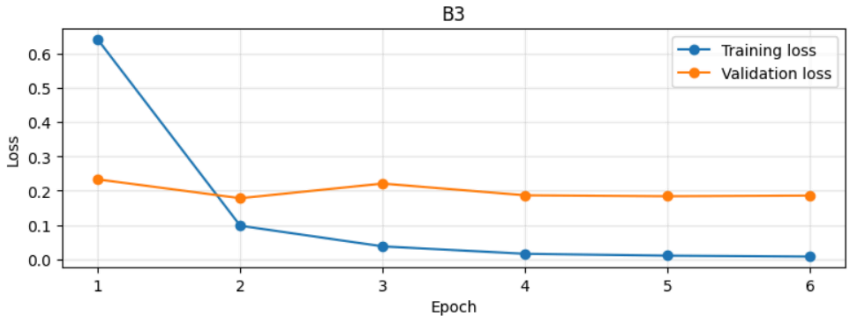
# Laporan dan Analisis Deep Learning

## C1-1. Tabel Konsolidasi dan Visualisasi Pembelajaran

| Kondisi | Strategi | Trainable parameters | Learning rate | Epoch dijalankan | Best epoch | Durasi | Best validation accuracy | Test Macro F1 |
|---|---|---|---|---|---|---|---|---|
| B1 | ResNet-18, inisialisasi acak, seluruh model dilatih | 11,181,642 | 0.001 | 13 | 9 | 3.38 menit | 45.8% | 0.421 |
| B2 | ResNet-18 pretrained, backbone dibekukan, hanya fc dilatih | 5,130 | 0.001 | 23 | 19 | 4.77 menit | 97.0% | 0.946 |
| B3 | ResNet-18 pretrained, layer4 dan fc dilatih | 8,398,858 | layer4: 0.0001; fc: 0.001 | 6 | 2 | 1.34 menit | 97.0% | 0.933 |
| B4 tanpa augmentasi | Kondisi B3, tanpa augmentasi | 8,398,858 | layer4: 0.0001; fc: 0.001 | 6 | 2 | 1.26 menit | 97.0% | 0.933 |
| B4 dengan augmentasi | Kondisi B3, dengan augmentasi | 8,398,858 | layer4: 0.0001; fc: 0.001 | 8 | 4 | 2.44 menit | 93.9% | 0.950 |
| B5 | EfficientNet-B0 pretrained, blok fitur terakhir dan classifier dilatih | 424,970 | Blok terakhir: 0.0001; classifier: 0.001 | 29 | 25 | 7.08 menit | 96.3% | 0.967 |




## C2. Pembahasan Analisis Komparatif

1. *Mengapa terjadi disparitas performa yang tajam antara pelatihan dari nol (B1) dengan paradigma transfer learning (B2 & B3)?*

B1 memperoleh validation accuracy 45,8% dan test Macro F1 0,421. Hasil B2 dan B3 jauh lebih tinggi: keduanya mencapai validation accuracy 97,0%, dengan test Macro F1 masing-masing 0,946 dan 0,933.

Perbedaan tersebut berkaitan dengan titik awal model. B1 memulai dari bobot acak, sehingga harus mempelajari fitur visual—seperti tepi, tekstur, bentuk, dan ciri ras—dari data eksperimen yang terbatas. B2 dan B3 menggunakan bobot pretrained yang sudah memuat representasi visual dari ImageNet. Model hanya perlu menggunakan atau menyesuaikan representasi tersebut untuk membedakan 10 kelas hewan pada eksperimen ini. Dengan data terbatas, titik awal pretrained memberi keuntungan besar.

2. *Bagaimana trade-off performa vs. stabilitas antara feature extraction murni dan fine-tuning bertahap pada volume data terbatas yang Anda miliki?*

B2 adalah feature extraction: backbone dibekukan dan hanya classifier fc yang dilatih. Jumlah parameter yang dilatih hanya 5.130. Pendekatan ini membatasi perubahan pada representasi pretrained, sehingga prosesnya relatif stabil dan risiko model menyesuaikan diri terlalu jauh pada data latih lebih kecil.

B3 membuka layer4 selain classifier, sehingga 8.398.858 parameter dapat dilatih. Ini memberi model lebih banyak ruang untuk menyesuaikan fitur tingkat tinggi pada domain gambar kucing dan anjing. Training loss B3 turun sangat cepat, tetapi validation loss terbaik tercapai pada epoch 2 lalu tidak membaik secara konsisten. Hal ini menunjukkan penyesuaian lebih cepat, tetapi juga memberi tanda bahwa model berpotensi terlalu menyesuaikan diri pada data latih.

Pada hasil eksperimen ini, B2 memiliki test Macro F1 0,946, lebih tinggi daripada B3 (0,933), walaupun keduanya memperoleh validation accuracy 97,0%. Jadi, fine-tuning tambahan pada B3 belum menghasilkan peningkatan performa uji dibandingkan feature extraction B2.

3. *Sejauh mana peran augmentasi (B4) dalam meredam overfitting (perhatikan celah selisih akurasi data latih terhadap data validasi)?*

Dibandingkan skenario tanpa augmentasi, skenario dengan augmentasi menghasilkan validation accuracy lebih rendah (93,9%, dibandingkan 97,0%). Namun, test Macro F1-nya lebih tinggi (0,950, dibandingkan 0,933). Ini menunjukkan bahwa dalam eksperimen ini, dampak augmentasi berbeda tergantung metrik: akurasi validasi turun, sementara keseimbangan performa antar kelas pada test set meningkat.

Untuk menyimpulkan apakah augmentasi meredam overfitting, kita perlu membandingkan overfitting gap kedua skenario, dengan rumus: *Overfitting gap = train accuracy − validation accuracy.*

Nilai train accuracy B4 belum tercantum di tabel, sehingga bagian ini belum dapat memastikan apakah augmentasi benar-benar memperkecil gap. Setelah nilai train accuracy tanpa augmentasi dan dengan augmentasi tersedia, analisis ini bisa dilengkapi dengan perbandingan angka gap-nya.

## C3. Failure Analysis (Analisis Kasus Misklasifikasi)

Kesalahan prediksi dari sampel citra yang ditemukan dari test set oleh model terbaik (B5):




| No. | Ground truth | Citra input | Confidence score | Hipotesis penyebab kesalahan |
|---|---|---|---|---|
| 1 | British Shorthair | Abyssinian | 42.1% | Kucing tampak dari sudut agak tinggi dan tubuhnya berada di dekat bayangan. Ciri wajah dan pola bulu ras tidak terlihat jelas, sehingga model mungkin memakai warna bulu sebagai petunjuk utama. |
| 2 | Basset Hound | Beagle | 65.7% | Kedua ras memiliki ciri anjing hound dan warna bulu yang dapat serupa. Foto close-up memperlihatkan wajah dan telinga, tetapi tidak menampilkan proporsi tubuh dan kaki yang dapat membantu membedakan keduanya. |
| 3 | Boxer | Basset Hound | 49.2% | Anjing tampak dari jarak jauh dan sedang berbaring di kursi. Bentuk wajah dan tubuh sulit diamati; latar dan pose lebih dominan daripada ciri ras. |
| 4 | Abyssinian | Bengal | 66.4% | Close-up wajah memperlihatkan pola bulu abu-abu yang mungkin dianggap model sebagai pola khas Bengal. Tubuh dan pola bulu keseluruhan tidak tampak. |
| 5 | Abyssinian | Bengal | 67.9% | Foto hanya menampilkan sebagian wajah dari samping, dengan bulu cokelat dan latar luar ruangan. Sudut serta bagian tubuh yang terpotong membuat ciri pembeda ras sulit diperiksa. |
| 6 | Abyssinian | British Shorthair | 49.3% | Kucing berwarna terang dan difoto dari samping. Warna bulu serta bentuk tubuh pada sudut ini mungkin lebih menyerupai representasi British Shorthair yang dipelajari model. |

| | | | | |
|---|---|---|---|---|
| 7 | Beagle | Basset Hound | 64.2% | Foto sangat dekat dan hanya menampilkan sebagian wajah. Kedua kelas memiliki warna bulu serta bentuk telinga yang mirip; ciri seperti panjang kaki dan proporsi tubuh tidak terlihat. |
| 8 | American Bulldog | Boxer | 42.2% | Anjing difoto dari atas saat berbaring. Wajah tidak terlihat jelas, sementara warna bulu putih-cokelat dan postur tubuh yang terpotong dapat membingungkan model. |

## C4. Rekomendasi Rekayasa dan Batasan Eksperimen

### Rekomendasi rekayasa

Berdasarkan hasil eksperimen, EfficientNet-B0 (B5) menjadi pilihan saat prioritas utama adalah performa per kelas: test Macro F1 tertinggi, yaitu 0,967, dengan 424.970 trainable parameters dan durasi pelatihan 7,08 menit. Model ini sesuai bila tim memiliki akses ke bobot pretrained, preprocessing yang kompatibel, dan anggaran komputasi yang memungkinkan waktu pelatihan sedikit lebih lama.

Jika batasan utama adalah jumlah parameter yang perlu diperbarui selama training, ResNet-18 B2 menjadi alternatif yang lebih ringan: hanya 5.130 trainable parameters, durasi 4,77 menit, dan test Macro F1 0,946. B2 cocok sebagai baseline transfer learning yang sederhana saat data terbatas dan tim ingin membatasi perubahan pada backbone. Perlu dicatat, jumlah trainable parameters bukan jumlah keseluruhan parameter model: B2 tetap memiliki 11.181.642 total parameters.

B3 dan B4 menunjukkan bahwa membuka lebih banyak layer atau menambahkan augmentasi tidak otomatis meningkatkan semua metrik. Karena itu, strategi akhir sebaiknya ditentukan berdasarkan kebutuhan operasional: prioritaskan Macro F1 jika performa antar-kelas penting, atau prioritaskan biaya pelatihan dan kesederhanaan jika sumber daya terbatas. Pemilihan model dilakukan berdasarkan validation set; test set digunakan untuk pelaporan evaluasi akhir.

### Batasan eksperimen

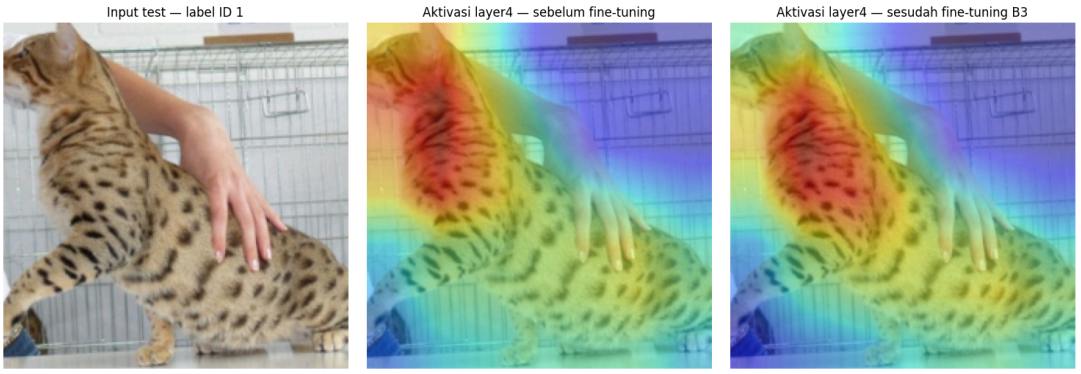
Eksperimen ini menggunakan satu seed dan satu pembagian data. Hasilnya dapat berubah ketika seed atau pembagian data berubah. Pengulangan dengan beberapa seed atau penggunaan cross-validation dapat memberikan gambaran performa yang lebih kuat. Dataset juga terbatas pada 10 kelas dan jumlah gambar yang tersedia, sehingga hasil belum tentu mewakili ras lain atau gambar dari lingkungan produksi.

Durasi pelatihan bergantung pada perangkat dan kondisi runtime. Karena itu, perbandingan waktu hanya bermakna jika eksperimen dijalankan dengan kondisi komputasi yang sebanding; jenis perangkat yang digunakan perlu dicantumkan dalam laporan. Pengujian augmentasi juga hanya mencakup satu kombinasi transformasi, sehingga belum menunjukkan dampak semua strategi augmentasi yang mungkin.

Seluruh konfigurasi dievaluasi pada test set yang sama. Oleh karena itu, hasil test sebaiknya dipakai sebagai evaluasi akhir, sementara pemilihan konfigurasi dilakukan

berdasarkan validation set. Jika test Macro F1 digunakan untuk memilih model terbaik, estimasi performa akhirnya berisiko menjadi terlalu optimistis.

## C5. Eksplorasi Tambahan (Nilai Tambah / Opsional)




pergeseran representasi visual sebelum dan sesudah fine-tuning B3 terlihat **kecil**, keduanya sama-sama menunjukkan aktivasi kuat di sekitar kepala dan bahu kucing. Setelah fine-tuning, aktivasi tampak sedikit lebih terkonsentrasi di area kepala dan bahu, sementara bagian belakang tubuh tidak tampak menjadi area respons utama.

Ini menunjukkan bahwa model pretrained sudah memiliki fitur visual yang berguna, fine-tuning kemudian menyesuaikan responnya secara terbatas terhadap gambar hewan. Karena visualisasi ini adalah rata-rata aktivasi layer4 untuk satu gambar, bukan Grad-CAM, hasilnya hanya menunjukkan pola aktivasi umum. Kita tidak dapat menyimpulkan bahwa daerah tersebut pasti menjadi dasar keputusan ras model atau bahwa pola yang sama berlaku untuk semua gambar.

## Lampiran

AI Disclosure Statement

1. Nama model/alat AI yang digunakan: ChatGPT (OpenAI)
2. Ruang lingkup bantuan AI pada tugas ini: memeriksa dan memperbaiki sintaks kode, memperbaiki error, membantu membuat visualisasi, memperbaiki bahasa laporan yang formal, menjelaskan konsep deep learning.
3. Cara Anda memverifikasi kebenaran keluaran AI tersebut secara mandiri: kode diperiksa satu per satu, youtube tutorial untuk referensi, tidak membiarkan AI mengetik kode.